

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ - ĐHQGHN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO GIỮA KỲ
HỌC PHẦN PHÂN TÍCH MẠNG PHƯƠNG TIỆN XÃ HỘI
MẠNG LƯỚI CÁC DIỄN VIÊN VÀ ĐẠO DIỄN QUỐC TẾ

Nhóm 6

22024521 - Lưu Quang Khải
22024520 - Lê Hồng Triệu
22024558 - Lương Gia Khánh

Mã học phần: 2526I_INT3235E_1

Giảng viên: TS. Trần Mai Vũ

HÀ NỘI - 2025

GIỚI THIỆU

Trong bối cảnh chuyển đổi số phát triển mạnh mẽ, lượng dữ liệu về các mối liên kết và tương tác giữa con người không ngừng tăng cả về quy mô lẫn độ phức tạp. Việc phân tích các cấu trúc mạng lưới trở thành công cụ quan trọng giúp khám phá mối quan hệ tiềm ẩn, hiểu rõ cơ chế vận hành của hệ thống và nhận diện các yếu tố có ảnh hưởng trong nhiều lĩnh vực. Một trong những lĩnh vực tiêu biểu có thể ứng dụng phương pháp này là ngành công nghiệp điện ảnh, nơi tồn tại mạng lưới quan hệ chặt chẽ giữa diễn viên, đạo diễn, nhà sản xuất và tác phẩm điện ảnh. Việc áp dụng Phân tích Mạng Xã hội (Social Network Analysis – SNA) và mô hình hóa các mối quan hệ này dưới dạng đồ thị giúp khám phá cấu trúc hợp tác, xác định cá nhân trung tâm, đồng thời mở ra tiềm năng ứng dụng trong gợi ý phim, phân tích xu hướng hay dự đoán thị hiếu khán giả.

Từ ý nghĩa đó, trong khuôn khổ học phần Phân tích Mạng Phương tiện Xã hội, nhóm tiến hành thực hiện đề tài “Xây dựng Mạng lưới các Diễn viên và Đạo diễn Quốc tế”. Để đảm bảo tính khả thi, phạm vi được giới hạn ở các diễn viên và đạo diễn mang quốc tịch Hoa Kỳ có bài viết trên Wikipedia Tiếng Việt. Mục tiêu của dự án là xây dựng cơ sở dữ liệu đồ thị phản ánh chính xác các mối quan hệ chuyên môn (diễn xuất, đạo diễn, sản xuất phim) và cá nhân (gia đình, hợp tác), đáp ứng yêu cầu tối thiểu về quy mô mạng lưới theo đề bài.

Để hiện thực hóa mục tiêu này, nhóm sử dụng Wikidata làm nguồn dữ liệu tri thức mở và truy xuất thông tin bằng SPARQL, sau đó xử lý qua pipeline tự động được xây dựng bằng Python theo quy trình ETL (Trích xuất – Chuyển đổi – Làm sạch – Tải dữ liệu). Dữ liệu được lưu trữ và phân tích trên Neo4j, cơ sở dữ liệu đồ thị có khả năng biểu diễn quan hệ tự nhiên và hiệu suất truy vấn cao.

Báo cáo này trình bày có hệ thống toàn bộ quá trình triển khai dự án, bao gồm phân công nhiệm vụ, thiết kế mô hình đồ thị, các công nghệ sử dụng, và pipeline xử lý dữ liệu. Phần tiếp theo trình bày kết quả thực nghiệm cùng các truy vấn minh họa bằng Cypher, qua đó thể hiện khả năng khai thác mạng lưới. Cuối cùng, báo cáo tổng kết những kết quả đạt được, hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai.

Mục lục

1	Phân công công việc	1
2	Giới thiệu về mạng	2
2.1	Đề tài và phạm vi	2
2.2	Thiết kế Mô hình Dữ liệu - Lựa chọn Nút	2
2.3	Thiết kế Mô hình Dữ liệu - Lựa chọn Cạnh	3
3	Công nghệ sử dụng	5
3.1	Nguồn dữ liệu - Wikidata	5
3.2	Ngôn ngữ và Pipeline	5
3.3	Cơ sở dữ liệu đồ thị	5
4	Quy trình xây mạng	7
4.1	Thu thập dữ liệu	7
4.2	Trích xuất và tổng hợp dữ liệu	7
4.3	Lọc và Đảm bảo Chất lượng Mạng	8
4.4	Nhập dữ liệu và Xây dựng Đồ thị	8
5	Phân tích và Thống kê Mạng Lưới	10
5.1	Thống kê Dữ liệu	10
5.2	Phân tích mạng lưới	10
5.2.1	Tổng quan đặc trưng mạng	10
5.2.2	Phân tích đặc trưng mạng diễn viên–phim	11
5.2.3	Phân tích mức độ trung tâm	12
5.2.4	Mối quan hệ giữa phim và đạo diễn	13

6	Kết luận	15
6.1	Thành tựu	15
6.2	Hạn chế và Hướng phát triển	15

Danh mục hình vẽ và bảng biểu

Danh sách hình vẽ

- 5.1 So sánh các chỉ số trung tâm của 10 diễn viên hàng đầu 13
- 5.2 So sánh giữa top phim có nhiều diễn viên tham gia (trái) và top đạo diễn có mạng lưới hợp tác rộng nhất (phải) 14

Danh sách bảng

- 5.1 Tổng quan đặc trưng cấu trúc của mạng 11
- 5.2 Tóm tắt các phim và đạo diễn có mức độ kết nối cao nhất 14

Chương 1: Phân công công việc

Thành viên	Công việc thực hiện
Lưu Quang Khải	Thu nhập dữ liệu, Xây dựng đồ thị, Sửa báo cáo
Lê Hồng Triệu	Thu nhập dữ liệu, Triển khai công nghệ lưu trữ, Viết báo cáo
Lương Gia Khánh	Phân tích dữ liệu, Triển khai công nghệ lưu trữ, Viết báo cáo

Các thành viên hoạt động tốt trong quá trình thực hiện dự án, mức độ đóng góp tương đương nhau.

Github dự án: Social-Network-Analysis-Team 6

Chương 2: Giới thiệu về mạng

2.1. Đề tài và phạm vi

Theo yêu cầu của bài tập lớn, nhóm đã lựa chọn đề tài "Mạng lưới các diễn viên và đạo diễn Quốc tế". Đây là một đề tài có ý nghĩa thực tiễn cao, cho phép áp dụng các kỹ thuật phân tích mạng xã hội (Social Network Analysis - SNA) vào một lĩnh vực được công chúng quan tâm. Tuy nhiên, phạm vi "Quốc tế" là quá rộng, có thể dẫn đến một tập dữ liệu khổng lồ, khó kiểm soát và phân tích.

Do đó, nhóm đã quyết định thu hẹp phạm vi nghiên cứu thành: "Mạng lưới các Diễn viên và Đạo diễn có quốc tịch Hoa Kỳ và có bài viết trên Wikipedia Tiếng Việt". Lựa chọn này dựa trên ba lý do chính: (1) Ngành công nghiệp điện ảnh Hoa Kỳ (Hollywood) có tầm ảnh hưởng toàn cầu và sở hữu nguồn dữ liệu phong phú, chi tiết trên Wikidata; (2) Việc giới hạn quốc tịch giúp tập trung phân tích vào một cộng đồng cụ thể; và (3) Yêu cầu lọc theo "Wikipedia Tiếng Việt" được tuân thủ nghiêm ngặt, đảm bảo tính liên kết của dữ liệu theo yêu cầu đề bài.

Nguồn dữ liệu chính được sử dụng là Wikidata, một cơ sở tri thức tự do, có cấu trúc, đóng vai trò là kho lưu trữ trung tâm cho dữ liệu của Wikipedia. Chúng em khai thác dữ liệu này thông qua dịch vụ SPARQL Endpoint.

2.2. Thiết kế Mô hình Dữ liệu - Lựa chọn Nút

Việc thiết kế mô hình nút là nền tảng cho bất kỳ CSDL đồ thị nào. Để đảm bảo tính linh hoạt và khả năng truy vấn hiệu quả, nhóm đã sử dụng chiến lược đa nhãn (multi-label) của Neo4j. Mạng lưới được xây dựng bao gồm ba loại nhãn nút chính:

:Person: Đây là nhãn cơ sở, được gán cho tất cả các thực thể là "con người" trong đồ thị, bao gồm diễn viên, đạo diễn, và cả những người liên quan (như thành viên gia đình). Nút này chứa các thuộc tính chung như name (tên) và qid (mã định danh Wikidata).

:ActorDirector: Đây là một nhãn phụ, được gán thêm cho các nút *:Person* nào được xác định là diễn viên hoặc đạo diễn (thông qua bộ lọc nghề nghiệp wdt:P106). Việc sử dụng nhãn phụ này mang lại lợi ích lớn về hiệu suất, cho phép chúng tôi nhanh chóng truy vấn chỉ các nhân vật trung tâm của mạng lưới mà không cần quét toàn bộ các nút *:Person*.

Các nút này chứa các thuộc tính chi tiết hơn như gender (giới tính) và viwikiURL (đường dẫn Wikipedia Tiếng Việt).

:Film: Nhãn này đại diện cho các tác phẩm điện ảnh, truyền hình hoặc kịch. Đây là các nút cầu nối (bridge nodes) quan trọng, liên kết các diễn viên và đạo diễn lại với nhau. Tương tự như *:Person*, nút *:Film* cũng sử dụng name và qid làm thuộc tính.

Nhóm sử dụng mã qid của Wikidata làm khóa tự nhiên (natural key) định danh duy nhất cho cả nút *:Person* và *:Film*. Trong script *4_import_to_neo4j.py*, chúng tôi đã định nghĩa các ràng buộc UNIQUE CONSTRAINT trên thuộc tính qid cho cả hai nhãn này. Điều này đảm bảo tính toàn vẹn dữ liệu, tránh việc tạo ra các nút trùng lặp và tối ưu hóa tốc độ của các thao tác MERGE, giúp cho quy trình nhập liệu trở nên an toàn và có thể chạy lại nhiều lần.

2.3. Thiết kế Mô hình Dữ liệu - Lựa chọn Cạnh

Gồm các nút là các thực thể người và phim, các cạnh chính là mối quan hệ liên kết của CSDL đồ thị, biểu diễn các tương tác có ý nghĩa. Nhóm đã ánh xạ các thuộc tính (P-ID) từ Wikidata thành các loại quan hệ có tên gọi ngữ nghĩa trong Neo4j. Các cạnh này được chia thành hai nhóm chính:

Quan hệ Chuyên môn (Nghề nghiệp): Đây là các cạnh cốt lõi, trực tiếp liên kết các nút *:ActorDirector* với các nút *:Film*, hình thành nên cấu trúc mạng lưới công việc.

ACTED_IN (từ P161): Biểu thị quan hệ "đã tham gia diễn xuất", dành cho các diễn viên có tham gia bộ phim.

DIRECTED (từ P57): Biểu thị quan hệ "đã đạo diễn", dành cho đạo diễn tham gia đạo diễn bộ phim.

PRODUCED (từ P162): Biểu thị quan hệ "đã sản xuất", dành cho đạo diễn tham gia sản xuất bộ phim.

Quan hệ Cá nhân (Gia đình): Các cạnh này cung cấp thêm một chiều sâu xã hội cho mạng lưới, liên kết các nút *:Person* (bao gồm cả *:ActorDirector*) với nhau.

IS_CHILD_OF (từ P22 - Cha, và P25 - Mẹ)

IS_PARENT_OF (từ P40 - Con cái)

IS_SPOUSE_OF (từ P26 - Vợ/Chồng)

IS_PARTNER_OF (từ P451 - Bạn tình)

IS_SIBLING_OF (từ P3373 - Anh/Chị em)

HAS_GRANDPARENT_OF (từ P1038 - Ông/Bà)

Sự kết hợp của hai nhóm quan hệ này cho phép thực hiện các truy vấn phân tích đa dạng, từ việc tìm kiếm các cộng tác viên chuyên môn (ví dụ: ”tìm 5 diễn viên đóng chung nhiều phim nhất với ’Tom Hanks’”) đến việc khám phá các mối liên kết xa như diễn viên này có liên kết đến diễn khác thông qua đạo diễn và bộ phim nào đó . Biến KEY_MAP trong script *4_import_to_neo4j.py* chính là từ điển ánh xạ, đóng vai trò cầu nối logic giữa dữ liệu thô từ SPARQL và lược đồ đồ thị ngữ nghĩa của Neo4j.

Chương 3: Công nghệ sử dụng

Việc lựa chọn công nghệ phù hợp là yếu tố quan trọng đến dự án. Nhóm đã lựa chọn các công nghệ dựa trên tính mở, sự phổ biến, và khả năng đáp ứng tốt các yêu cầu của bài toán.

3.1. Nguồn dữ liệu - Wikidata

Wikidata là nguồn dữ liệu tổng thể cung cấp dữ liệu có cấu trúc, được liên kết và có thể được truy vấn một cách thông qua ngôn ngữ truy vấn đồ thị (SPARQL). Wikipedia Tiếng Việt được sử dụng như một bộ lọc điều kiện (`schema:isPartOf <https://vi.wikipedia.org>`) trong các câu lệnh SPARQL, đảm bảo mọi thực thể được chọn đều có trên dữ liệu wikipedia tiếng Việt, tuân thủ yêu cầu đề bài.

3.2. Ngôn ngữ và Pipeline

Python3 được chọn làm ngôn ngữ lập trình chính để xây dựng toàn bộ quy trình xử lý dữ liệu. Python là lựa chọn lý tưởng cho các tác vụ khoa học dữ liệu và ETL (Extract, Transform, Load) nhờ vào hệ sinh thái thư viện phong phú và cú pháp rõ ràng.

Thư viện `sparqlwrapper` được sử dụng để tạo kết nối tới SPARQL Endpoint của Wikidata và thực thi các truy vấn một cách tự động, nhận về kết quả dưới dạng cấu trúc (thường là JSON).

Thư viện `neo4j` cung cấp driver chính thức để kết nối ứng dụng Python với CSDL Neo4j, cho phép thực thi các câu lệnh Cypher để tạo ràng buộc và nhập dữ liệu.

Các thư viện chuẩn như `json`, `os`, `glob` và `time` được sử dụng để xử lý tệp, quản lý đường dẫn và điều phối thời gian chờ giữa các lệnh gọi API, đảm bảo quy trình pipeline chạy ổn định.

3.3. Cơ sở dữ liệu đồ thị

Trong số các hệ quản trị CSDL được đề xuất (Neo4j, Elasticsearch, ArangoDB), nhóm đã lựa chọn Neo4j. Đây là một hệ quản trị CSDL đồ thị thuần túy (native graph database) hàng đầu, được thiết kế tối ưu cho việc lưu trữ và truy vấn các mối quan hệ.

Lý do lựa chọn Neo4j thay vì các CSDL quan hệ (SQL) hay CSDL tài liệu (như ArangoDB) là vì mô hình của Neo4j (Property Graph Model) ánh xạ trực tiếp 1:1 với bài toán. Các diễn viên/phim là các nút (node) và các mối quan hệ (đóng chung, đạo diễn, gia đình) là các cạnh (relationship). Việc này cho phép thực thi các truy vấn duyệt quan hệ (graph traversal) ở độ sâu bất kỳ (ví dụ: tìm "bạn của bạn của bạn") tốt, một tác vụ mà CSDL quan hệ (SQL) thực hiện tốn kém thông qua các phép JOIN lồng nhau. Ngôn ngữ truy vấn Cypher của Neo4j, với cú pháp "ASCII-Art" trực quan (ví dụ (p1)-[:ACTED_IN]->(f)), làm cho việc truy vấn và phân tích mạng lưới trở nên đơn giản và dễ đọc. Cuối cùng, công cụ Neo4j Bloom đi kèm cung cấp khả năng trực quan hóa mạnh mẽ, giúp khám phá dữ liệu một cách trực quan.

Chương 4: Quy trình xây mạng

4.1. Thu thập dữ liệu

Giai đoạn đầu tiên, được thực thi bởi `1_run_discovery.py`, có mục tiêu thu thập một danh sách cơ sở (gồm QID, tên, URL Wikipedia) của tất cả các nhân vật phù hợp với phạm vi đề tài.

Một thách thức lớn khi làm việc với các SPARQL Endpoint công cộng là chúng thường có giới hạn về thời gian thực thi (timeout) và số lượng kết quả trả về. Truy vấn lấy tất cả sẽ thất bại. Để giải quyết vấn đề này, script đã áp dụng chiến lược ”truy vấn theo lô” (batch query). Chúng em thực hiện truy vấn lấy danh sách các diễn viên theo từng khoảng độ tuổi và giới tính.

Hàm `build_discovery_query` sử dụng câu lệnh SPARQL cho từng khoảng năm sinh, lọc nghiêm ngặt theo: Quốc gia (`wdt:P27 = wd:Q30` - Hoa Kỳ), Nghề nghiệp (`wdt:P106 = wd:Q33999` - Diễn viên hoặc `wd:Q2526255` - Đạo diễn), và sự tồn tại của bài viết trên Wikipedia Tiếng Việt. Thực hiện chạy riêng cho từng giới tính và khoảng tuổi (1940-1949, 1950-1959,...). Kết quả của mỗi lô truy vấn được lưu thành một tệp JSON riêng biệt (ví dụ: `actors_woman_1980_1989.json`) trong thư mục `output/lists/`.

4.2. Trích xuất và tổng hợp dữ liệu

Sau khi có được danh sách thô, `2_run_extraction.py` thực hiện hai nhiệm vụ chính: lọc trùng lặp và làm giàu dữ liệu (data enrichment).

Đầu tiên, script đọc tất cả các tệp JSON từ Bước 1. Bằng cách sử dụng QID làm khóa (key), script đã tự động hợp nhất và loại bỏ các bản ghi trùng lặp.

Với danh sách QID lấy được, script lặp qua từng nhân vật và thực thi một truy vấn SPARQL thứ hai. Truy vấn này sử dụng UNION để đồng thời lấy về (A) các thông tin cơ bản (gia đình, quốc tịch, v.v.) và (B) các thông tin quan hệ chuyên môn (phim đã tham gia, đạo diễn, sản xuất).

Hàm `format_infobox` có tác dụng sắp xếp lại dữ liệu trả về thành cấu trúc JSON phân cấp, nhóm các giá trị theo từng thuộc tính. Kết quả là một tệp JSON tổng hợp,

`all_actors_infoboxes.json`, chứa thông tin chi tiết của tất cả các nhân vật.

4.3. Lọc và Đảm bảo Chất lượng Mạng

Script `3_filter_actors.py` hoạt động là một bộ lọc đảm bảo chất lượng (Quality Assurance filter).

Logic của script này như sau: một nhân vật có thể được Wikidata gán nhãn là "diễn viên" hoặc "đạo diễn", nhưng nếu họ không có bất kỳ mối liên hệ nào với một tác phẩm phim (:Film) trong tập dữ liệu của chúng ta, sự tồn tại của họ trong mạng lưới sẽ không có ý nghĩa và làm loãng kết quả phân tích.

Do đó, script này đọc tệp JSON tổng hợp từ Bước 2 và kiểm tra infobox của từng người. Nó sử dụng danh sách `FILM_KEYS_TO_CHECK` (bao gồm P161 - Đóng phim, P162 - Sản xuất, và P57 - Đạo diễn). Nếu một nhân vật không có ít nhất một mục trong bất kỳ khóa nào thuộc ba khóa này, họ sẽ bị loại bỏ khỏi tập dữ liệu. Kết quả là tệp `all_actors_infoboxes_FILTERED.json`, một phiên bản "sạch" chỉ chứa các nhân vật thực sự tham gia vào mạng lưới điện ảnh.

4.4. Nhập dữ liệu và Xây dựng Đồ thị

Đây là bước cuối cùng, dữ liệu cấu trúc được chuyển đổi thành đồ thị trong Neo4j, sử dụng script `4_import_to_neo4j.py`.

Đầu tiên, script thực thi các lệnh `CREATE CONSTRAINT` để đảm bảo không có hai node `Person` hay `Film` có cùng giá trị `qid`. Sau đó, script lặp qua từng nhân vật trong tệp JSON đã lọc. Với mỗi nhân vật, nó thực hiện:

MERGE nút chính: `MERGE (p:Person qid: $qid)` để tạo hoặc cập nhật nút `:Person`. Sau đó, dùng `SET p:ActorDirector` để gán thêm nhãn phụ cho nút này.

Lặp qua infobox: Với mỗi quan hệ (ví dụ: P161 - `ACTED_IN`):

- Sử dụng `KEY_MAP` để tìm ra tên quan hệ Cypher (ví dụ: `ACTED_IN`).
- Xác định nhãn của nút đích (là `:Film` nếu `PID` nằm trong `FILM_KEYS`, ngược lại là `:Person`).
- Thực thi một câu lệnh Cypher thứ hai, lồng bên trong, để `MERGE` nút đích (ví dụ: `MERGE (p2:Film qid: $entry_qid)`) và sau đó `MERGE` mỗi quan hệ giữa chúng

(ví dụ: `MERGE (p1) - [r:ACTED_IN] -> (p2)`).

Việc sử dụng `MERGE` thay vì `CREATE` ở mọi bước đảm bảo rằng nếu script được chạy lại, nó sẽ không tạo ra dữ liệu trùng lặp mà chỉ cập nhật thông tin (nếu có), một đặc tính quan trọng cho sự ổn định của pipeline.

Chương 5: Phân tích và Thống kê Mạng Lưới

5.1. Thống kê Dữ liệu

Kết quả bước thu thập: Giai đoạn thu thập thô ban đầu tìm thấy tổng cộng 2189 lượt đề cập đến nhân vật (1305 nam và 884 nữ). Con số này chứa các bản ghi trùng lặp kết quả khi truy vấn.

Kết quả giai đoạn trích xuất và tổng hợp: Sau khi tải tất cả dữ liệu thô và lọc trùng lặp bằng QID, số lượng nhân vật duy nhất được xác định là 1799.

Kết quả giai đoạn lọc: Đây là con số quan trọng nhất. Sau khi áp dụng bộ lọc chất lượng (loại bỏ các nhân vật không có liên kết phim), số lượng nhân vật trung tâm (diễn viên/đạo diễn được nhóm công nhận) cuối cùng được đưa vào mạng lưới là 1264.

Một phân tích thú vị là tỉ lệ lọc: $(1799 - 1264) / 1799 \approx 30\%$. Điều này có nghĩa là khoảng 30% số người được Wikidata gán nhãn là diễn viên/đạo diễn (và có bài viết tiếng Việt) thực tế lại không có bất kỳ liên kết nào đến một tác phẩm phim cụ thể trong cơ sở dữ liệu. Điều này khẳng định tầm quan trọng của Bước 3 trong việc xây dựng một mạng lưới chất lượng và có ý nghĩa.

5.2. Phân tích mạng lưới

5.2.1. Tổng quan đặc trưng mạng

Mạng lưới *diễn viên-phim* trong cơ sở dữ liệu Neo4j mô tả các mối liên hệ giữa con người và tác phẩm điện ảnh, phản ánh mức độ hợp tác và tương tác trong ngành công nghiệp phim. Phần này trình bày cái nhìn tổng quan về cấu trúc mạng thông qua các chỉ số cơ bản như số lượng nút, số lượng cạnh, mật độ và bậc trung bình của nút. Những chỉ số này giúp đánh giá quy mô, sự phân bố kết nối và tính chặt chẽ của mạng.

Các giá trị được thống kê bao gồm: tổng số nút (chia theo loại), tổng số quan hệ (chia theo kiểu kết nối), mật độ mạng và bậc trung bình của nút.

- **Mật độ mạng (Network Density)** phản ánh mức độ kết nối của toàn mạng, được

tính theo công thức:

$$D = \frac{2E}{N(N-1)}$$

trong đó E là tổng số cạnh (quan hệ), và N là tổng số nút trong mạng. Giá trị D nằm trong khoảng $[0, 1]$; giá trị càng cao thì mạng càng dày đặc, tức là các nút có xu hướng kết nối với nhau nhiều hơn.

- **Bậc trung bình (Average Degree)** cho biết trung bình mỗi nút có bao nhiêu kết nối:

$$\langle k \rangle = \frac{2E}{N}$$

Chỉ số này giúp hình dung mức độ liên kết trung bình giữa các thực thể trong mạng.

Chỉ số	Giá trị
Tổng số nút trong mạng	5816
Số nút loại :Person	3916
Số nút loại :Film	1900
Số nút loại :ActorDirector	1264
Tổng số quan hệ	10818
Số quan hệ :ACTED_IN	6301
Số quan hệ :DIRECTED	556
Số quan hệ :PRODUCED	632
Mật độ mạng (Network Density)	0.00064
Bậc trung bình của nút (Average Degree)	3.72

Bảng 5.1: Tổng quan đặc trưng cấu trúc của mạng

5.2.2. Phân tích đặc trưng mạng diễn viên–phim

Dựa trên các chỉ số trong **Bảng 5.1**, có thể nhận thấy rằng mạng *diễn viên–phim* có quy mô khá lớn với hơn 5.800 nút và hơn 10.000 quan hệ. Tuy nhiên, mật độ mạng chỉ đạt $D = 0.00064$, cho thấy cấu trúc mạng rất thưa — các nút chỉ kết nối thông qua những bộ phim chung, thay vì liên kết trực tiếp giữa các cá nhân.

Chỉ số bậc trung bình $k = 3.72$ phản ánh rằng mỗi thực thể (diễn viên hoặc phim) trung bình chỉ có khoảng bốn kết nối, thể hiện đặc trưng phân tán và đa dạng trong mối quan hệ hợp tác.

Quan hệ ACTED_IN chiếm tỷ lệ cao nhất (hơn 58% tổng số cạnh), phản ánh bản chất

trung tâm của các diễn viên trong mạng, trong khi các quan hệ DIRECTED và PRODUCED có số lượng thấp hơn đáng kể. Điều này cho thấy thông tin về đạo diễn và nhà sản xuất tuy quan trọng nhưng đóng vai trò kết nối phụ trợ, không chi phối cấu trúc chính của mạng.

Tổng thể, đồ thị mang đặc trưng của một mạng hai phía (bipartite network), trong đó các nút người và phim tạo thành hai tập riêng biệt. Cấu trúc này giúp thể hiện rõ ràng mối quan hệ hợp tác trong ngành điện ảnh, đồng thời tạo nền tảng thuận lợi cho các bước phân tích sâu hơn như phát hiện cộng đồng hoặc xác định trung tâm ảnh hưởng trong mạng.

5.2.3. Phân tích mức độ trung tâm

Phân tích mức độ trung tâm (*centrality analysis*) được thực hiện nhằm xác định các cá nhân có vai trò nổi bật trong mạng — tức là những người giữ vai trò kết nối, trung gian hoặc có tầm ảnh hưởng cao đối với toàn bộ hệ thống. Ba chỉ số trung tâm phổ biến được sử dụng trong nghiên cứu mạng xã hội gồm:

- **Degree Centrality (C_D):** phản ánh mức độ kết nối trực tiếp của một nút, được tính theo công thức:

$$C_D(v) = \frac{\deg(v)}{N - 1}$$

trong đó $\deg(v)$ là số lượng kết nối của nút v , và N là tổng số nút trong mạng.

- **Betweenness Centrality (C_B):** thể hiện vai trò “cầu nối” của một nút trong việc trung gian giữa các cặp nút khác, tính bằng:

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$


với σ_{st} là số đường đi ngắn nhất giữa s và t , và $\sigma_{st}(v)$ là số đường trong đó đi qua nút v .

- **PageRank (C_P):** đo lường tầm ảnh hưởng tổng thể của một nút dựa trên liên kết đến từ các nút khác, được tính theo:

$$C_P(v) = (1 - \alpha) + \alpha \sum_{u \in M(v)} \frac{C_P(u)}{L(u)}$$

với $\alpha = 0.85$ là hệ số suy giảm, $M(v)$ là tập các nút liên kết đến v , và $L(u)$ là số liên

kết đi ra từ u .



Hình 5.1: So sánh các chỉ số trung tâm của 10 diễn viên hàng đầu

Dựa trên kết quả phân tích, có thể thấy rằng **Samuel L. Jackson** là nhân vật nổi bật nhất trong mạng với giá trị cao ở cả ba chỉ số trung tâm, thể hiện vai trò trung tâm trong việc kết nối nhiều nhóm diễn viên khác nhau. **Chris Evans**, **Robert Downey Jr.**, và **Josh Brolin** cũng cho thấy tầm ảnh hưởng lớn, phản ánh mối quan hệ hợp tác chặt chẽ trong vũ trụ điện ảnh Marvel.

Các diễn viên như **Channing Tatum**, **Mark Ruffalo**, hay **Scarlett Johansson** có chỉ số betweenness cao, thể hiện vai trò cầu nối giữa các cụm diễn viên thuộc nhiều dòng phim khác nhau.


Nhìn chung, mạng lưới có xu hướng tập trung quanh một số cá nhân có tầm ảnh hưởng toàn mạng, phản ánh cấu trúc “ngôi sao” đặc trưng trong ngành điện ảnh, nơi một nhóm nhỏ diễn viên nổi bật đóng vai trò trung tâm trong việc duy trì và lan tỏa mối liên kết giữa các cộng đồng phim khác nhau.

5.2.4. Mối quan hệ giữa phim và đạo diễn

Phần này tập trung vào các nút :Film và :Director, nhằm phân tích:

- Các phim có nhiều diễn viên tham gia nhất.
- Các đạo diễn có mạng lưới hợp tác rộng nhất.

Kết quả cho thấy sự khác biệt rõ rệt giữa mức độ kết nối của các bộ phim bom tấn và tầm ảnh hưởng của các đạo diễn nổi tiếng.



Hình 5.2: So sánh giữa top phim có nhiều diễn viên tham gia (trái) và top đạo diễn có mạng lưới hợp tác rộng nhất (phải)

Phim	Số diễn viên	Đạo diễn	Số cộng tác viên
Avengers: Endgame	35	Steven Spielberg	79
Avengers: Infinity War	23	Christopher Nolan	47
Spider-Man: Homecoming	18	James Gunn	47
Movie 43	17	Michael Bay	47
Grown Ups 2	16	Shawn Levy	44
The Muppets	16	Brett Ratner	41
F9	16	David Fincher	40
Batman v Superman: Dawn of Justice	16	Quentin Tarantino	37
Guardians of the Galaxy	16	Martin Scorsese	36
The Disaster Artist	15	Robert Rodriguez	36

Bảng 5.2: Tóm tắt các phim và đạo diễn có mức độ kết nối cao nhất

Các bộ phim thuộc vũ trụ điện ảnh Marvel như *Avengers: Endgame* và *Infinity War* dẫn đầu về số lượng diễn viên, phản ánh quy mô lớn và tính liên kết cao giữa nhiều nhân vật trong cùng hệ thống phim. Ngược lại, các đạo diễn như *Steven Spielberg*, *Christopher Nolan* và *James Gunn* thể hiện vai trò trung tâm trong mạng lưới hợp tác — họ thường xuyên làm việc với nhiều diễn viên qua nhiều dự án khác nhau. Điều này cho thấy sự giao thoa giữa các cụm trung tâm: một bên là các tác phẩm bom tấn đa nhân vật, bên còn lại là các đạo diễn có ảnh hưởng mạnh trong ngành điện ảnh hiện đại.

Chương 6: Kết luận

Qua quá trình triển khai đề tài “Xây dựng Mạng lưới các Diễn viên và Đạo diễn Quốc tế” (giới hạn phạm vi tại Hoa Kỳ), nhóm đã thu được nhiều kết quả quan trọng, đồng thời rút ra được những kinh nghiệm thực tế trong việc ứng dụng kỹ thuật phân tích mạng lưới vào dữ liệu tri thức mở.

6.1. Thành tựu

Hoàn thành mục tiêu xây dựng mạng lưới: Nhóm đã thành công trong việc thiết lập cơ sở dữ liệu đồ thị biểu diễn mạng lưới quan hệ của 1264 diễn viên và đạo diễn Hoa Kỳ, cùng với hàng nghìn nút phim và nhân vật liên quan khác. Số lượng này đáp ứng điều kiện đề bài, thể hiện khả năng mở rộng và độ bao phủ tốt của hệ thống.

Phát triển pipeline dữ liệu tự động: Một quy trình ETL hoàn chỉnh gồm bốn giai đoạn – trích xuất, chuyển đổi, làm sạch và tải dữ liệu – đã được xây dựng bằng Python. Pipeline này tự động hóa quá trình thu thập dữ liệu từ Wikidata thông qua SPARQL, đảm bảo tính chính xác, khả năng lặp lại và dễ bảo trì trong các lần mở rộng sau.

Làm chủ công nghệ và mô hình dữ liệu: Nhóm đã vận dụng hiệu quả các công cụ và công nghệ chủ đạo gồm Wikidata SPARQL Endpoint, Python (các thư viện `sparqlwrapper`, `neo4j`) và cơ sở dữ liệu đồ thị Neo4j.

Đảm bảo chất lượng dữ liệu và cấu trúc mạng lưới: Thông qua giai đoạn làm sạch dữ liệu, các nút không có đóng góp ý nghĩa được loại bỏ, giúp mạng lưới tập trung vào các cá nhân thực sự hoạt động trong lĩnh vực điện ảnh. Điều này đảm bảo đồ thị thu được có tính thực tiễn và độ tin cậy cao.

Thực hiện phân tích và trực quan hóa cơ bản: Các truy vấn Cypher cơ bản đã được triển khai nhằm khám phá cấu trúc mạng (như tìm cộng tác viên, quan hệ bậc hai), đồng thời sử dụng công cụ trực quan hóa tích hợp trong Neo4j để biểu diễn đồ thị, minh họa rõ ràng các mối liên hệ trong hệ thống.

6.2. Hạn chế và Hướng phát triển

Mặc dù đạt được những kết quả tích cực, dự án vẫn tồn tại một số hạn chế cần được

cải thiện trong các giai đoạn tiếp theo:

Độ sâu dữ liệu còn hạn chế: Pipeline hiện chủ yếu tập trung làm giàu dữ liệu cho nhóm diễn viên và đạo diễn chính. Các thực thể liên kết (:Person, :Film) mới chỉ được khởi tạo ở mức cơ bản (tên, QID), khiến khả năng phân tích đa tầng chưa được khai thác đầy đủ.

Giới hạn phạm vi dữ liệu: Việc chỉ xem xét các thực thể có bài viết trên Wikipedia Tiếng Việt đã làm giảm độ bao quát của mạng lưới, loại bỏ nhiều cá nhân hoạt động trong ngành điện ảnh do chưa có bài viết tiếng Việt.

Phân tích mạng ở mức sơ cấp: Báo cáo hiện tập trung vào quy trình xây dựng mạng lưới. Các kỹ thuật phân tích mạng xã hội chuyên sâu hơn chưa được áp dụng.

Từ các hạn chế trên, nhóm đề xuất một số hướng phát triển trong tương lai như sau:

Mở rộng và làm giàu dữ liệu: Hoàn thiện pipeline để có thể khai thác sâu hơn các nút liên kết, thu thập thêm thông tin chi tiết cho các thực thể phụ nhằm hình thành đồ thị đa tầng phong phú hơn. Có thể xem xét nói lỏng tiêu chí Wikipedia Tiếng Việt để tăng độ toàn diện của dữ liệu.

Ứng dụng các thuật toán phân tích đồ thị nâng cao: Sử dụng thư viện Graph Data Science (GDS) hoặc các công cụ tương tự để triển khai các kỹ thuật như Community Detection (phát hiện nhóm hợp tác), Centrality Measures (xác định mức độ ảnh hưởng), Pathfinding (phân tích đường đi ngắn nhất) và Link Prediction (dự đoán hợp tác tiềm năng).

Phát triển công cụ trực quan hóa tương tác: Xây dựng giao diện web trực quan cho phép người dùng tìm kiếm, lọc và khám phá mạng lưới theo hướng tương tác.

Tổng kết lại, dự án đã cơ bản hoàn thiện cho việc xây dựng mạng lưới các diễn viên và đạo diễn quốc tế (Hoa Kỳ), đồng thời mở ra nhiều hướng nghiên cứu và ứng dụng mở rộng. Những kết quả đạt được là tiền đề quan trọng để nhóm tiếp tục hoàn thiện và phát triển hệ thống trong tương lai.

Xin cảm ơn!